Machine Learning dla detekcji Hardware Trojans

Autorzy:

Adrian Danek
Łukasz Janczycki

Spis Treści

1. Wstęp i kontekst teoretyczny 2
   a) Streszczenie 3
   b) Ewolucja Zagrożeń w Łańcuchu Dostaw Układów Scalonych 3
   c) Klasyfikacja i Mechanika Działania Koni Trojańskich 3
   d) Analiza Kanałów Bocznych jako Metoda Detekcji 4
2. Definicja projektu i zakres realizacji 4
3. Konfiguracja środowiska laboratoryjnego 5
   Stos technologiczny 6
   Dane testowe 6
   Instalacja środowiska 6
4. Analiza próbek 6
5. Implementacja mechanizmu obronnego: Metodologia uczenia maszynowego 8
   Inżynieria Cech i Przetwarzanie Sygnału (Preprocessing) 8
   Zbiory danych 8
   Modele AI: 8
6. Wyniki eksperymentu i ewaluacja obrony 8
   Porównanie modeli dla AES-T500 8
   Pełna tabelka modeli i zbiorów danych (dokładność) 8
7. Wnioski 8
8. Bibliografia 8

1. Wstęp i kontekst teoretyczny

a) Streszczenie

Niniejsza praca przedstawia zastosowanie metod uczenia maszynowego (Machine Learning) oraz głębokiego uczenia (Deep Learning) do detekcji koni trojańskich w układach scalonych (Hardware Trojans). Wykorzystując analizę kanałów bocznych (Side-Channel Analysis) w domenie poboru mocy, przebadano skuteczność czterech modeli: SVM, Random Forest, MLP oraz CNN. Badania przeprowadzono na zbiorze danych z układu FPGA SAKURA-G. Wyniki wykazały najwyższą skuteczność sieci MLP (do 94% dla AES-T500) oraz 100% wykrywalność trojanów typu CDMA (AES-T800), potwierdzając, że analiza SCA wspomagana sztuczną inteligencją jest skuteczną metodą weryfikacji bezpieczeństwa układów scalonych.

b) Ewolucja Zagrożeń w Łańcuchu Dostaw Układów Scalonych

Współczesny przemysł półprzewodnikowy przeszedł drastyczną transformację z modelu wertykalnie zintegrowanego (gdzie jedna firma projektuje i produkuje układy) do modelu horyzontalnego. W tym ekosystemie, właściciele własności intelektualnej (IP Vendors) projektują układy, ale ich fizyczna fabrykacja zlecana jest zewnętrznym, często zagranicznym odlewniom (Foundries). Choć model ten optymalizuje koszty, wprowadza fundamentalną lukę w zaufaniu: zewnętrzny producent ma pełny dostęp do maski fotolitograficznej i może wprowadzić złośliwe modyfikacje na poziomie tranzystorów.

Hardware Trojan (HT) definiowany jest jako celowa, złośliwa modyfikacja układu scalonego, wprowadzona na etapie projektu lub produkcji, mająca na celu zmianę jego funkcjonalności, wyciek informacji lub doprowadzenie do awarii. W przeciwieństwie do oprogramowania złośliwego (malware), HT jest trwałą zmianą fizyczną, niemożliwą do usunięcia za pomocą "łatki" programowej, co czyni go zagrożeniem o najwyższym priorytecie dla systemów krytycznych, takich jak infrastruktura wojskowa, medyczna czy finansowa.

c) Klasyfikacja i Mechanika Działania Koni Trojańskich

Zrozumienie mechanizmu ataku jest kluczowe dla opracowania skutecznej obrony. Zgodnie z taksonomią przyjętą w literaturze (Trust-Hub), trojany charakteryzują się dwoma głównymi komponentami:

Mechanizm Aktywacji (Trigger): Warunek, który musi zostać spełniony, aby trojan przeszedł ze stanu uśpienia w stan aktywny.

- **Digital Trigger:** Konkretna sekwencja bitów na wejściu lub licznik cykli zegara. Są one niezwykle trudne do wykrycia metodami losowymi, ponieważ prawdopodobieństwo ich przypadkowego uruchomienia jest bliskie zeru (tzw. "rare events").
- **Analog Trigger**: Aktywacja pod wpływem temperatury, napięcia lub zewnętrznego sygnału radiowego.

Ładunek (Payload): Działanie wykonywane po aktywacji.

- **Information Leakage**: Modulacja poboru mocy lub opóźnień w celu przesłania tajnych kluczy (np. w AES) kanałem bocznym.
- **Functional Modification**: Zmiana uprawnień procesora, wyłączenie szyfrowania.
- **Denial of Service (DoS)**: Fizyczne uszkodzenie układu (np. poprzez elektromigrację) lub wejście w pętlę nieskończoną.

d) Analiza Kanałów Bocznych jako Metoda Detekcji

Tradycyjne metody weryfikacji, takie jak inspekcja optyczna (Reverse Engineering) czy testy logiczne, są nieefektywne. Inspekcja optyczna jest destrukcyjna i kosztowna, a testy logiczne nie pokrywają miliardów możliwych stanów aktywacji trojana.

Rozwiązaniem jest Analiza Kanałów Bocznych (Side-Channel Analysis - SCA). Każdy tranzystor w układzie CMOS, nawet nieaktywny logicznie, generuje pewien pobór mocy statycznej (prądy upływu) oraz wpływa na impedancję sieci zasilającej. Podczas przełączania generuje moc dynamiczną.

Równanie mocy całkowitej układu CMOS można przedstawić jako:

$$P_{total} = P_{dynamic} + P_{static} = (\alpha C_L V^2_{dd} f_{clk}) + (I_{leak} V_{dd})$$

Gdzie dodatkowe bramki trojana zwiększają pojemność pasożytniczą C_L oraz prąd upływu I_{leak}. Nawet jeśli trojan jest "uśpiony", jego fizyczna obecność zmienia sygnaturę energetyczną układu.10 Wyzwaniem jest fakt, że te zmiany są rzędu nano-watów i giną w szumie procesowym (Process Variation - PV) oraz szumie pomiarowym. Tu kluczową rolę odgrywa uczenie maszynowe, które potrafi ekstrahować nieliniowe wzorce z zaszumionych danych wielowymiarowych.

2. Definicja projektu i zakres realizacji

Celem projektu jest stworzenie automatycznego klasyfikatora z wykorzystaniem uczenia maszynowego. Do analizy zostanie wykorzystany dataset, który zawiera analizę elektryczną chipów za pomocą oscyloskopu. Link do datasetów znajduje się na końcu pracy.

W podanym wcześniej zbiorze znajdują się próbki podzielone na: Trojan Disabled czyli z nieaktywnym trojanem, oraz z Trojan Triggered czyli aktywnym.

Na podstawie przebiegu linii w oscyloskopie model będzie miał na celu odróżniać który układ jest zainfekowany, a który jest bezpieczny.

Zgodnie z dokumentacją zbioru danych, układy poddano testom w stałej temperaturze tj. 25°C. Miało to na celu uniknięcie zwiększonego poboru prądu wraz ze wzrostem temperatury.

Zbiory danych

Zbiór	Warunek aktywacji (Trigger)	Payload (Działanie złośliwe)
AES-T400	Zdefiniowana wartość na wejściu	Wyciek klucza poprzez sygnał RF
AES-T500	Zdefiniowana sekwencja liczb na wejściu	Drenaż baterii (ciągła rotacja rejestru przesuwnego)
AES-T600	Zdefiniowana wartość na wejściu	Wyciek klucza poprzez zwiększenie prądu upływu (leakage current) dla każdego bitu '0'
AES-T800	Zdefiniowana sekwencja liczb na wejściu	Wyciek klucza jako kod sekwencji CDMA (kanał ukryty)
AES-T1000	Zdefiniowana wartość na wejściu	Wyciek klucza jako kod sekwencji CDMA (kanał ukryty)
AES-T1600	Zdefiniowana sekwencja liczb na wejściu	Wyciek klucza poprzez sygnał RF

Modele AI

Model AI	Typ	Główne cechy w kontekście SCA (Power/EM Analysis)	Zalety przy wykrywaniu Trojanów	Wady / Wyzwania
SVM (Support Vector Machine)	Klasyczny ML	Szuka optymalnej hiperpłaszczyzny oddzielającej próbki z trojanem od tych bez.	Dobrze radzi sobie, gdy cechy są wyraźne i wymiarowość została zredukowana (np. przez PCA). Skuteczny na małych zbiorach danych.	Bardzo wolny przy dużej liczbie próbek treningowych. Wymaga **ręcznego wyboru cech** (Points of Interest) – nie zadziała dobrze na surowym, długim przebiegu.
Random Forest (RF)	Klasyczny ML (Ensemble)	Zbiór drzew decyzyjnych. Ocenia ważność poszczególnych punktów w czasie dla klasyfikacji.	**Interpretowalność:** Pozwala określić, w którym momencie czasu (którym cyklu zegara) trojan się aktywuje (Feature Importance). Odporny na szum.	Podobnie jak SVM, gorzej radzi sobie z surowymi danymi, jeśli nie są idealnie wyrównane (zsynchronizowane).
MLP (Multi-Layer Perceptron)	Deep Learning (Podstawowy)	Sieć w pełni połączona. Każdy punkt wykresu jest wejściem do każdego neuronu pierwszej warstwy.	Potrafi modelować nieliniowe zależności, których nie widzi prosta korelacja. Lepszy od SVM przy dużej ilości danych.	**Podatny na desynchronizację.** Jeśli "pik" zużycia energii przesunie się o 10 punktów, MLP traktuje to jako zupełnie nową cechę. Łatwo o przeuczenie (overfitting) przy długich wejściach.
CNN (Convolutional Neural Network)	Deep Learning (Zaawansowany)	Wykorzystuje sploty (filtry) do szukania wzorców lokalnie, przesuwając się po wykresie.	**Złoty standard w SCA.** Posiada cechę **Shift-Invariance** (niezmienniczość na przesunięcia) – wykryje wzorzec ataku nawet, jeśli sygnał jest przesunięty w czasie (jitter). Nie wymaga wstępnej obróbki (działa na surowych danych).	"Black box" – trudniej wyjaśnić, dlaczego sieć podjęła decyzję. Wymaga dużej mocy obliczeniowej (GPU) i czasu na trening.

Kod wszystkich modeli dołączony w plikach

3. Konfiguracja środowiska laboratoryjnego

Stos technologiczny

Projekt zaimplementowano w języku Python 3.8+, wykorzystując następujące biblioteki specjalistyczne:

- jupyterlab==4.6.0a0
- matplotlib==3.10.8
- numpy==2.4.0
- pandas==2.3.3
- scikit-learn==1.8.0
- seaborn==0.13.2
- xgboost==3.1.2
- tensorflow==2.20.0

Wszystkie podane powyżej pakiety znajdują się w pliku "requirements.txt" dołączonym do projektu.

Dane testowe

Dane zostały zebrane z platformy sprzętowej **SAKURA-G FPGA**. Pomiary wykonywano przy użyciu oscyloskopu podłączonego do wzmacniaczy i sond pomiarowych.

https://ieee-dataport.org/open-access/hardware-trojan-power-em-side-channel-dataset

Instalacja środowiska

1. Utworzenie środowiska:
   "python -m venv ht_project_env"
2. Aktywacja środowiska python:
   "cd ht_project_env"
   ".\Scripts\activate"
3. Aktualizujemy menedżer pakietów:
   "python -m pip install --upgrade pip"
4. Kopiujemy plik requirements do katalogu
5. Instalujemy potrzebne pakiety z pliku requirements
   "pip install requirements.txt"

4. Analiza próbek

W niniejszym rozdziale przedstawiono graficzną reprezentację surowych danych czasowych (time-series signals), które stanowią wejście dla opracowanych modeli uczenia maszynowego. Każdy z poniższych wykresów reprezentuje emisję fizyczną układu FPGA (pobór mocy lub emisję EM) zarejestrowaną w przedziale czasowym między podaniem tekstu jawnego a odebraniem zaszyfrowanego wyniku z modułu AES.

Charakterystyka sygnału:

- **Związek z algorytmem AES:** Widoczne na wykresach okresowe fluktuacje odpowiadają kolejnym rundom szyfrowania AES-128. Każdy impuls jest wynikiem przełączania tysięcy bramek logicznych CMOS, co generuje mierzalny spadek napięcia w sieci zasilającej lub emisję fali elektromagnetycznej.
- **Wpływ danych wejściowych:** Amplituda i kształt poszczególnych "pików" zależą od wektora wejściowego oraz operacji matematycznych wykonywanych w danej chwili przez procesor kryptograficzny.
- **Wizualizacja anomalii:** Skrypt `display_probes.py` pozwala na nałożenie przebiegów dla stanu *Disabled* (bezpieczny) oraz *Triggered* (zainfekowany). W przypadku aktywacji trojana, ładunek złośliwy (payload) wymusza dodatkową aktywność przełączającą (np. ciągłą rotację rejestru przesuwnego w modelu AES-T500), co objawia się jako subtelna zmiana profilu energetycznego, często niewidoczna dla ludzkiego oka, ale ekstrahowalna przez algorytmy AI.

Prezentowane próbki zostały poddane wstępnemu przetwarzaniu, w tym usunięciu składowej stałej (DC offset removal) oraz normalizacji. Proces ten jest niezbędny, aby modele AI mogły skupić się na analizie dynamicznych zmian sygnatury energetycznej, a nie na przypadkowych różnicach w kalibracji oscyloskopu.

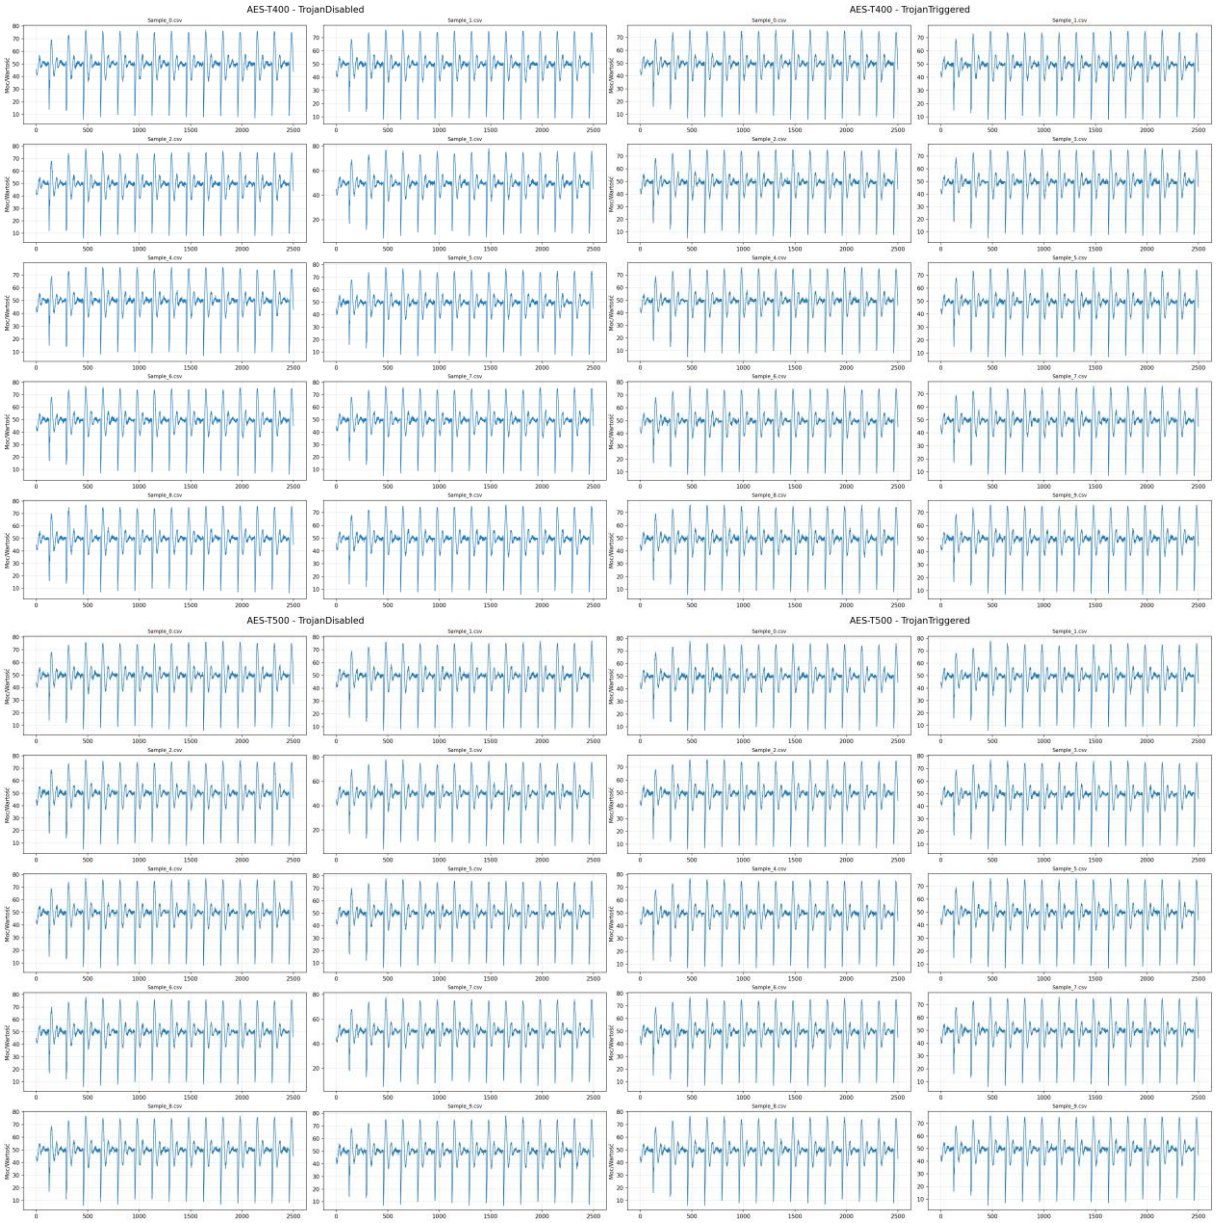
AES-T400 - TrojanDisabled
AES-T400 - TrojanTriggered
AES-T500 - TrojanDisabled
AES-T500 - TrojanTriggered

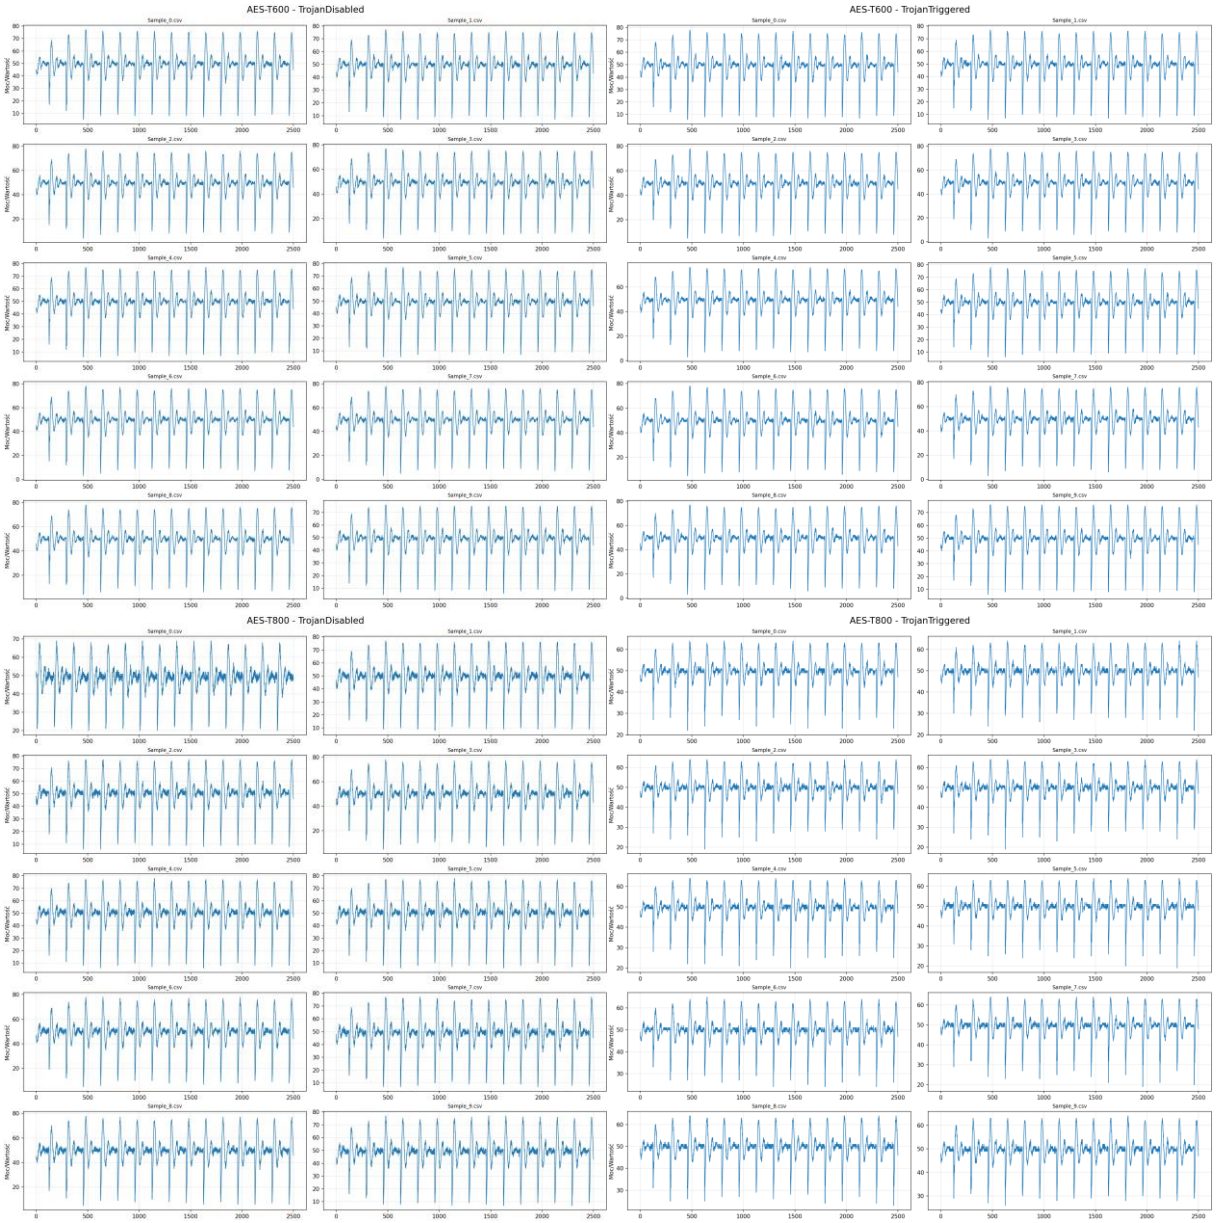
AES-T600 - TrojanDisabled
AES-T600 - TrojanTriggered
AES-T800 - TrojanDisabled
AES-T800 - TrojanTriggered

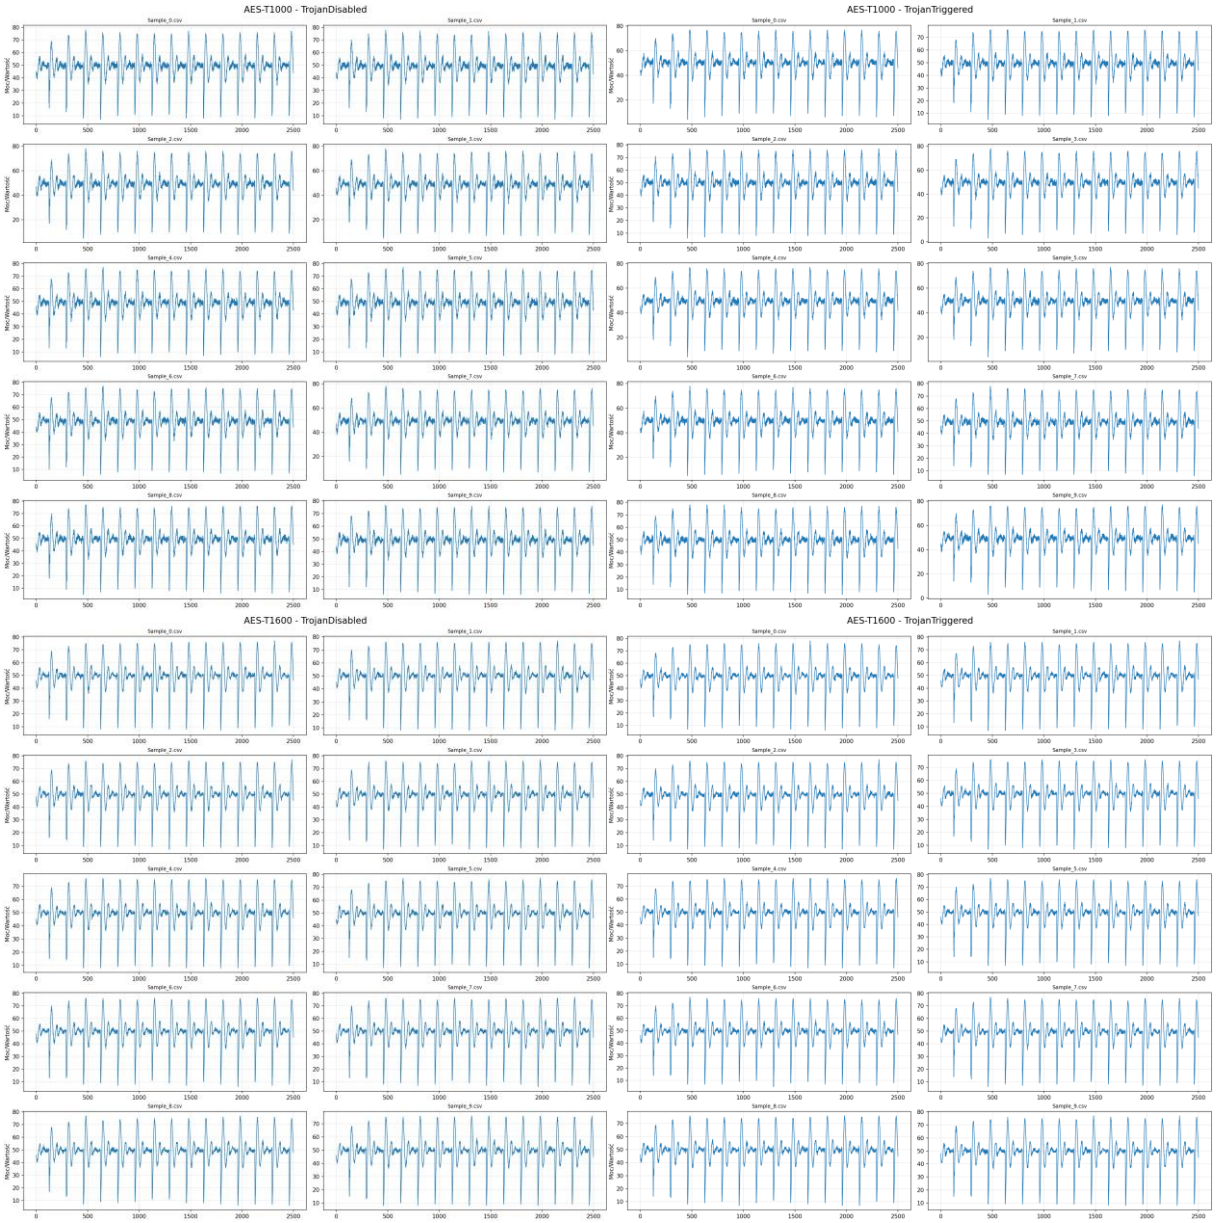
AES-T1000 - TrojanDisabled
AES-T1000 - TrojanTriggered
AES-T1600 - TrojanDisabled
AES-T1600 - TrojanTriggered

5. Implementacja mechanizmu obronnego: Metodologia uczenia maszynowego

W celu dokładnej implementacji mechanizmu obronnego zostały zastosowane różne Modele oraz zbiory danych.

Inżynieria Cech i Przetwarzanie Sygnału (Preprocessing)

Ze względu na wysoką częstotliwość próbkowania i zaszumienie pomiarów fizycznych (Side-Channel Analysis), surowe dane wymagały wstępnego przetworzenia. Dla każdego modelu zastosowano dedykowaną strategię preprocessingu:

- **Filtracja Szumu (dla Random Forest):** Zastosowano filtr średniej ruchomej (Rolling Mean) z oknem o wielkości 5 próbek. Pozwoliło to na wygładzenie nagłych skoków napięcia (tzw. glitche) niebędących częścią sygnału użytecznego.
- **Selekcja Cech (Feature Selection):**
    - Dla modelu **SVM** zastosowano algorytm **PCA (Principal Component Analysis)**, redukując przestrzeń cech do 50 głównych komponentów, co znacznie przyspieszyło trening bez utraty kluczowych informacji.
    - Dla **Random Forest** użyto metody **SelectKBest (ANOVA F-value)**, wybierając 500 punktów czasowych o największej wariancji między klasą bezpieczną a zainfekowaną.
- **Balansowanie Klas:** W zbiorze treningowym występuje naturalna dysproporcja (więcej próbek bezpiecznych). W modelach sieci neuronowych (CNN, MLP) oraz Random Forest zastosowano mechanizm **Class Weights**, który nadaje wyższą wagę błędom popełnianym na klasie mniejszościowej (Infected), zapobiegając dominacji klasy "Safe".

6. Wyniki eksperymentu i ewaluacja obrony

Poniżej zostaną przedstawione wykresy dla AES-T500 dla każdego z modeli. Następnie zostanie podana tabelka dokładności dla każdego z wcześniej wymienionych zbiorów danych oraz każdego modelu.

Porównanie modeli dla AES-T500

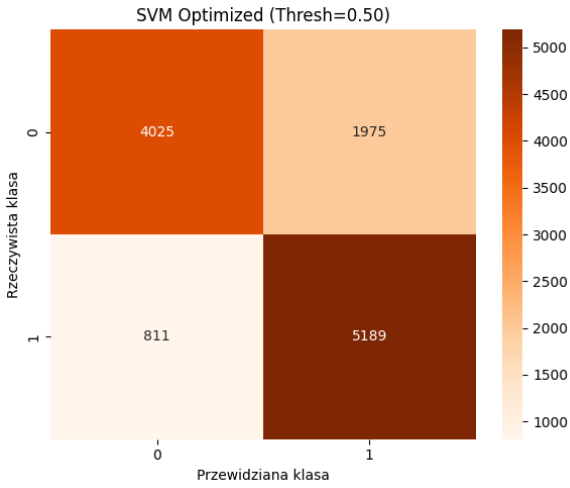

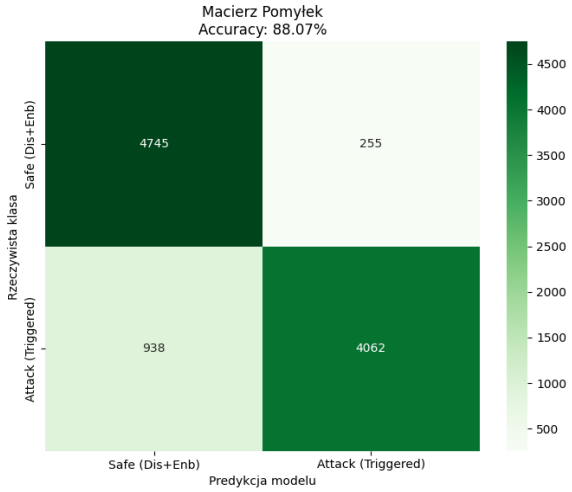

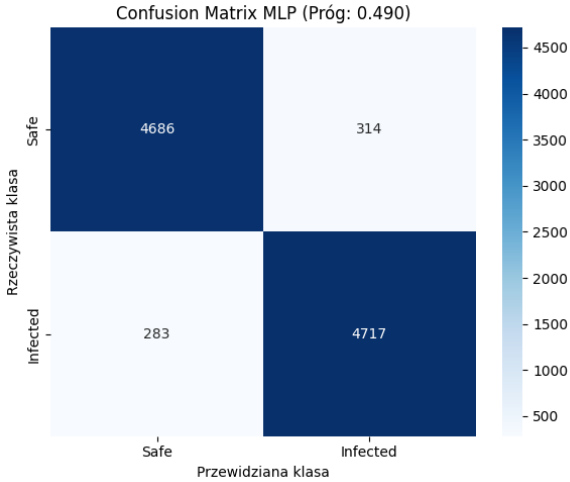

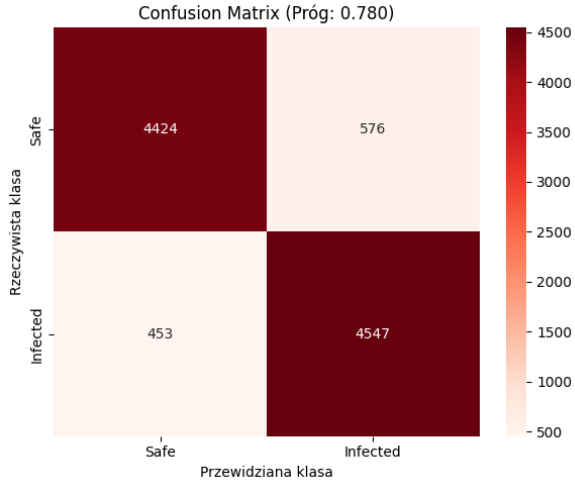

Wyniki przedstawiają przewagę deep learning(MLP, CNN) nad klasycznym machine learningiem(SVM, Random Forest), jednakże w przypadku Random Forest różnica nie jest bardzo znacząca.

Skuteczność to:

- SVM (pomarańczowy): 77%
- RandomForest (zielony): 88%
- MLP (niebieski): 94%
- CNN (brązowy): 90%

Pełna tabelka modeli i zbiorów danych (dokładność)

Model\Zbiór	AES-T400	AES-T500	AES-T600	AES-T800	AES-T1000	AES-T1600
SVM	62%	77%	65%	100%	77%	59%
Random Forest	70%	88%	86%	100%	79%	66%
MLP	79%	94%	92%	100%	82%	79%
CNN	67%	90%	69%	100%	56%	55%

Należy zwrócić uwagę na 100% skuteczność detekcji dla trojana **AES-T800** we **wszystkich modelach**. Wynika to ze specyfiki jego ładunku (payload) – trojan ten przesyła klucz metodą **CDMA** (Code Division Multiple Access), co generuje bardzo silne, szerokopasmowe zakłócenia w poborze mocy. Jest to trojan "głośny", łatwy do wykrycia nawet prostymi metodami statystycznymi, w przeciwieństwie do subtelnego AES-T1600 (wyciek radiowy RF), gdzie skuteczność modeli klasycznych spada do 59-66%.

Wszystkie dane wraz z wykresami dla poszczególnych modeli w dołączonym pliku wraz z kodem poszczególnych modeli w python!

W przypadku niektórych modeli oraz zbiorów danych sam klasyfikator, który osiąga bardzo wysoką skuteczność może służyć jako znakomita pomoc przy wykrywaniu niechcianego oprogramowania w układach scalonych, może niemal działać jako jedyny środek zaradczy. Jednakże w przypadku gorzej wypadających dokładności może służyć on jako wskazówka czy dany chip posiada Trojana.

7. Wnioski

Przeprowadzone badania eksperymentalne potwierdziły skuteczność metod uczenia maszynowego w detekcji sprzętowych koni trojańskich (Hardware Trojans) poprzez analizę poboru mocy (SCA).

Kluczowe obserwacje:

1. **Dominacja Głębokiego Uczenia:** Modele oparte na sieciach neuronowych (MLP i CNN) osiągnęły najwyższą średnią skuteczność (do 94% dla AES-T500). Model MLP okazał się najbardziej uniwersalny, radząc sobie najlepiej z nieliniowymi zależnościami w sygnale.
2. **Odporność na desynchronizację:** Sieci konwolucyjne (CNN) wykazały potencjał w analizie sygnałów przesuniętych w czasie (dzięki inwariantności translacyjnej splotu), co jest kluczowe w rzeczywistych warunkach, gdzie pomiary mogą nie być idealnie zsynchronizowane.
3. **Wydajność a Dokładność:** Algorytm Random Forest, po zastosowaniu odpowiedniej selekcji cech (SelectKBest), stanowił doskonały kompromis między czasem treningu a dokładnością (88% dla T500), przewyższając znacznie wolniejszy model SVM.

Ograniczenia i dalsze prace: Obecne badania przeprowadzono w stałej temperaturze 25°C. W rzeczywistych warunkach układy scalone pracują w szerokim zakresie temperatur, co wpływa na prądy upływu. Dalszym kierunkiem rozwoju projektu powinno być przetestowanie wytrenowanych modeli na danych zebranych w wyższych temperaturach (dostępnych w zbiorze do 85°C), aby zweryfikować ich stabilność termiczną oraz zastosowanie technik *Data Augmentation* w celu zwiększenia odporności na szum.

8. Bibliografia

[1] R. Yasaei, S. Faezi, M. A. Al Faruque, "Power and Electromagnetic Side-Channel Signals of Hardware Trojan Benchmarks," IEEE Dataport, 2021. [Online]. Dostępne: https://ieee-dataport.org/open-access/hardware-trojan-power-em-side-channel-dataset

[2] Y. Li, "An AI-Enabled Side-Channel Power Analysis Based Hardware Trojan Detection Method for Securing the Integrated Circuits in Cyber-Physical Systems," ResearchGate, 2024.

[3] Dokumentacja biblioteki Scikit-learn: https://scikit-learn.org/stable/

[4] Dokumentacja TensorFlow/Keras: https://www.tensorflow.org/api_docs